



Metallurgy QC

Data Augmentation

Flowchart

Lab Notes





Bài 2

CÁC KỸ THUẬT HUẤN LUYỆN VÀ TỐI ƯU HOÁ MÔ HÌNH

Giảng viên: ThS. Lê Thị Thùy Trang


Email: tranglt@dainam.edu.vn

Điện thoại: 0966730396

1. Hàm mất mát
2. Overfitting vs Underfitting
3. Thuật toán tối ưu hoá
4. Kỹ thuật điều chuẩn
5. Thực hành






HÀM MẮT MẮT




- ❖ Dữ liệu được sử dụng để huấn luyện mô hình phân loại lỗi bề mặt là **NEU Surface Defect Database** do nhóm nghiên cứu tại Northeastern University công bố rộng rãi, thường dùng làm benchmark trong nhiều nghiên cứu về phân loại/nhận dạng lỗi bề mặt thép.

- ❖ Dataset chứa 6 loại lỗi điển hình:
 - Rạn nứt (Crazing - Cr)
 - Lẫn tạp chất (Inclusion - In)
 - Vết loang (Patches - Pa)
 - Rỗ bề mặt (Pitted Surface - PS)
 - Vảy thép cuộn (Rolled-in Scale – RS)
 - Trầy xước (Scratches - Sc)






CASE STUDY



- ❖ Quá trình huấn luyện mạng nơ-ron thực chất là một bài toán tối ưu hóa.
- ❖ Hàm mất mát $\mathcal{L}(\theta)$ đo lường định lượng sự sai khác giữa dự đoán của mô hình $\hat{y}$ và nhãn thực tế y .
- ❖ Mục tiêu: Cực tiểu hóa giá trị của $\mathcal{L}(\theta)$ thông qua việc cập nhật tập hợp trọng số θ .
- ❖ Việc chọn sai hàm mất mát sẽ dẫn đến hiện tượng gradient bị triệt tiêu (Vanishing Gradient) hoặc hội tụ sai mục tiêu nghiệp vụ.




- ❖ In the realm of deep learning, a **Loss Function (or Cost Function)** serves as the mathematical compass for a neural network. It quantifies the error by calculating the precise distance between the model's current prediction and the actual ground truth. During the training process, the network aims to **minimize** this value iteratively through an optimization algorithm like Gradient Descent.
- ❖ **The choice of function fundamentally dictates how the model learns.** Regression tasks (predicting continuous quantities like house prices) typically employ MSE or MAE to measure numerical discrepancies. Classification tasks (predicting categories like "Spam" or "Not Spam") rely on Cross-Entropy to penalize probability divergences.

MSE LOSS FUNCTION

$$L = (y - \hat{y})^2$$

Penalizes large errors quadratically.




Tại sao không dùng MSE cho bài toán phân loại?



CROSS-ENTROPY LOSS FUNCTION

$$L = -(y \log(\hat{y}) + (1 - y) \log(1 - \hat{y}))$$

Logarithmic penalty for probability.



<https://datavizpyr.com/loss-function-visualizer/>

CASE STUDY

Cross-Entropy Loss ép mô hình phải đẩy xác suất của lớp đúng lên tiệm cận tuyệt đối.






ĐẠI NAM
UNIVERSITY

OVERFITTING VS UNDERFITTING



THE BIAS VARIANCE TRADE OFF

Interactive visualization of the bias variance trade off




THE BIAS VARIANCE TRADE OFF

- ❖ Độ chệch (Bias): sai số giữa dự đoán trung bình của mô hình và giá trị thực tế.
- ❖ Độ chệch của hàm ước tính cho chúng ta biết khả năng dự đoán giá trị của mô hình cơ bản.
- ❖ Phương sai (Variance): độ biến thiên trung bình trong dự đoán của mô hình đối với tập dữ liệu đã cho.
- ❖ Phương sai của hàm ước tính cho biết hàm đó có thể điều chỉnh như thế nào đối với sự thay đổi trong tập dữ liệu.

High Bias	→	Overly-simplified Model
	→	Under-fitting
	→	High error on both test and train data
High Variance	→	Overly-complex Model
	→	Over-fitting
	→	Low error on train data and high on test
	→	Starts modelling the noise in the input

THE BIAS VARIANCE TRADE OFF

Thảo luận về kết quả dự đoán của model trong các kịch bản dưới đây?



OVERFITTING VS UNDERFITTING



OVERFITTING VS UNDERFITTING



Không hứng thú học
Class test ~50%
Exam ~47%



Học vẹt
Class test ~98%
Exam ~69%



Hiểu bản chất
Class test ~92%
Exam ~89%

❖ **Quá khớp (overfitting):** mô hình dự đoán tốt trên tập huấn luyện nhưng không dự đoán tốt trên tập kiểm thử.

❖ Giải pháp giảm quá khớp:

- Giảm sự phức tạp của mô hình
- Tăng cường dữ liệu
- Chọn lọc feature
- Phương pháp điều chuẩn
- Early stopping
- Dropout


Overfitting






❖ **Vị khớp (underfitting):** mô hình dự đoán kém đồng thời trên cả tập huấn luyện và tập kiểm thử.

❖ Phương pháp khắc phục vị khớp:


- Tăng độ phức tạp của mô hình
- Huấn luyện lâu hơn
- Giảm regularization/dropout
- Kiểm tra lại preprocessing và learning rate
- Bổ sung dữ liệu chất lượng hơn



- ❖ Đường cong huấn luyện (Learning Curve) thường gồm hai đường: Loss train và Loss validation theo số epoch.
- ❖ Bằng cách quan sát sự thay đổi của hai đường này, ta có thể nhận biết mô hình đang học tốt hay gặp vấn đề.




CASE STUDY






ĐẠI NAM
UNIVERSITY

THUẬT TOÁN TỐI ƯU HOÁ



CASE STUDY




VISUALIZING OPTIMIZER DYNAMICS

Visualizing Optimizer Dynamics on a Loss Surface


Loss Function: Marker Size (px): Animation Speed: Surface Type: Weight Range:

Bias Range: Optimizer: Learning Rate: Beta1 (β_1): Beta2 (β_2):

Loss Surface (w vs b vs loss)



STOCHASTIC GRADIENT DESCENT & MOMENTUM



- ❖ **Stochastic gradient descent (SGD)** tính toán đạo hàm trên một lô dữ liệu nhỏ (mini-batch) và cập nhật trọng số ngược hướng dốc.

- ❖ Công thức SGD cơ bản:

$$\theta_{t+1} = \theta_t - \eta \nabla \mathcal{L}(\theta_t)$$

- ❖ **Momentum (động lượng)**: bằng cách tích lũy vector gradient của các bước trước đó, Momentum giúp mô hình “lăn” qua các điểm cực tiểu cục bộ và duy trì vận tốc ở các đoạn dốc thoải

- ❖ Công thức SGD+ Momentum:

$$v_{t+1} = \gamma v_t + \eta \nabla \mathcal{L}(\theta_t)$$

$$\theta_{t+1} = \theta_t - v_{t+1}$$

Quả cầu bây giờ có đà, nó vượt qua được những đoạn bằng phẳng và hội tụ nhanh hơn. Nhưng... vẫn còn một vấn đề: learning rate giống nhau cho tất cả các tham số.

Trong bài toán NEU, các đặc trưng về texture (vân thép) và loại edges (biên lỗi) có tần suất xuất hiện rất khác nhau trong 1.800 ảnh. Dùng cùng một learning rate cho tất cả là không công bằng.


PHÂN TÍCH TỐI ƯU HÓA MÔ HÌNH (NEU DATASET)

SO SÁNH ĐƯỜNG CÔNG LOSS (Epoch vs Loss)

- NEU dataset = 1,800 ảnh (Thép Lỗ Kỹ thuật)
- THUẬT TOÁN TỐI ƯU HÓA: SGD + MOMENTUM

momentum=0.9





- ❖ **Adam (Adaptive Moment Estimation):** giữ một tốc độ học riêng cho mỗi tham số để cải thiện hiệu suất trên các vấn đề có gradient thưa đồng thời điều chỉnh tốc độ học dựa trên mức độ thay đổi gần nhất của gradient, giúp xử lý các vấn đề có hàm mục tiêu không lồi.
- ❖ Adam duy trì 2 moment:

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) \nabla L \leftarrow \text{đà (1st moment)}$$


$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) (\nabla L)^2 \leftarrow \text{độ lớn gradient (2nd moment)}$$

$$\text{Bias correction: } \hat{m}_t = m_t / (1 - \beta_1^t), \hat{v}_t = v_t / (1 - \beta_2^t)$$

$$\text{Cập nhật: } \theta_{t+1} = \theta_t - \frac{\alpha \hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon}$$

$$\text{Default: } \beta_1 = 0.9, \beta_2 = 0.999, \epsilon = 10^{-8}$$

ADAM OPTIMIZER



CASE STUDY



- ❖ **W (Decoupled Weight Decay):** suy giảm trọng số được tách rời
- ❖ Cơ chế hoạt động: Thực hiện tính toán Adam xong, sau đó mới trừ trực tiếp một lượng $\lambda\theta_t$ ra khỏi trọng số.
- ❖ Công thức cập nhật AdamW:

$$\theta_{t+1} = \theta_t - \eta \left(\frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon} + \lambda\theta_t \right)$$

- ❖ Tác động: Giữ nguyên tốc độ hội tụ nhanh của Adam, nhưng vẫn tận dụng được Weight Decay để chống quá khớp.

Thuật toán	Cơ chế cốt lõi	Ưu điểm	Nhược điểm
SGD	Cập nhật theo gradient hiện tại	Khả năng tổng quát hóa rất cao. Rất mạnh trong CNNs.	Hội tụ chậm, khó cấu hình learning rate, dễ kẹt ở điểm yên ngựa.
Adam	Sử dụng momentum cho cả gradient bậc 1 và bậc 2.	Hội tụ cực kỳ nhanh, learning rate tự động điều chỉnh cho từng tham số.	Tương tác toán học kém với L2 regularization, dễ gây overfit.
AdamW	Adam + Weight Decay được tách rời độc lập.	Kết hợp tốc độ của Adam và khả năng tổng quát hóa của Weight Decay. Chuẩn mực hiện tại.	Phức tạp hơn SGD, đòi hỏi tinh chỉnh hệ số λ cẩn thận.




ĐẠI NAM
UNIVERSITY

KỸ THUẬT ĐIỀU CHUẨN



CASE STUDY



- ❖ **L2 regularization:** thêm một tham số phạt vào hàm mất mát dựa trên tổng bình phương độ lớn của các trọng số của mạng nơ-ron.
- ❖ Công thức: $\mathcal{L}_{total} = \mathcal{L}_{original} + \frac{\lambda}{2} \sum \theta^2$
- ❖ Tác động: Khiến các trọng số θ duy trì ở mức nhỏ, ngăn chặn bất kỳ nơ-ron nào phát triển trọng số quá lớn để **học thuộc lòng** nhiều cục bộ -> giảm phương sai.
- ❖ L2 regularization can thiệp trực tiếp vào hàm mất mát, trong khi weight decay can thiệp vào quá trình cập nhật trọng số

- ❖ **Dropout:** tại mỗi vòng lặp trong giai đoạn huấn luyện, vô hiệu hoá ngẫu nhiên một tỷ lệ ρ (ví dụ: $\rho = 0.3$) các nơ-ron trong một lớp mạng.
- ❖ Tác động: Phá vỡ sự "đồng thích nghi" (Co-adaptation) phức tạp giữa các nơ-ron. Ngăn chặn việc một nơ-ron chỉ biết dựa dẫm vào kết quả của nơ-ron đứng trước nó.
- ❖ Chế độ Suy luận (Inference/Evaluation): Mọi nơ-ron được bật lại. Trọng số tự động được nhân với tỷ lệ $(1 - \rho)$ để bảo toàn tổng mức năng lượng kỳ vọng của dòng chảy dữ liệu,

❖ **Batch normalization (BatchNorm)**: thực hiện phép chuẩn hoá trung bình (mean) và phương sai (variance) trên trục batch cho tín hiệu kích hoạt ngay trước hoặc sau hàm kích hoạt phi tuyến (như ReLU).

❖ Công thức:

$$\hat{x}_i = \frac{x_i - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}}$$



A Recipe for Training Neural Networks

Apr 25, 2019

Some few weeks ago I [posted](#) a tweet on “the most common neural net mistakes”, listing a few common gotchas related to training neural nets. The tweet got quite a bit more engagement than I anticipated (including a [webinar](#) :)). Clearly, a lot of people have personally encountered the large gap between “here is how a convolutional layer works” and “our convnet achieves state of the art results”.

So I thought it could be fun to brush off my dusty blog to expand my tweet to the long form that this topic deserves. However, instead of going into an enumeration of more common errors or fleshing them out, I wanted to dig a bit deeper and talk about how one can avoid making these errors altogether (or fix them very fast). The trick to doing so is to follow a certain process, which as far as I can tell is not very often documented. Let's start with two important observations that motivate it.





Thank You!

DAINAM
UNIVERSITY